

Data oddania: _____

Ocena: _____

Hubert Gawłowski 224298

Kamil Kiszko-Zgierski 224328

Projekt 1. Klasyfikacja dokumentów tekstowych

1. Cel projektu

Celem zadania jest zaimplementowanie algorytmu k -NN w technologii Java na potrzeby klasyfikacji tekstów oraz zbadanie wpływu wybranych cech liczbowych i tekstowych na skuteczność powyższej metody. W wyniku działania algorytmu teksty zostaną przyporządkowane do krajów, z jakich pochodzą. Badanie zostanie przeprowadzone na podstawie artykułów prasowych z agencji prasowej Reuters, które to pochodzą z 1987 roku, wszystkie teksty napisane są w języku angielskim, a przy klasyfikacji pod uwagę będą brane artykuły, które pochodzą z następujących krajów: Republika Federalna Niemiec, USA, Francja, Wielka Brytania, Kanada, Japonia.

2. Klasyfikacja nadzorowana metodą k -NN

Algorytm k -NN (od angielskich słów nearest neighbour - najbliższy sąsiad) to algorytm, którego działanie polega na przyporządkowaniu obiektu poddanego rozpoznawaniu do jednej z klas. Do wykorzystania tego algorytmu niezbędny jest zestaw klas, do których może należeć obiekt, zbiór danych uczących oraz rozpoznawany obiekt. Metoda k -NN należy do grupy metod minimalnoodległościowych, ponieważ o zaklasyfikowaniu obiektu do danej klasy decyduje najmniejsza odległość (zgodna z przyjętą metryką), pomiędzy rozpoznawanym obiektem oraz k -obiektami z ciągu uczącego. Wyszukiwanie

najmniejszej odległości pomiędzy obiektami można przedstawić za pomocą wzoru ogólnego:

$$\rho(x, x^{i,k}) = \min_{x^\mu \in U^i} (x, x^\mu) \quad (1)$$

gdzie ρ to wybrana metryka, U^i oznacza ciąg uczący, $x^{i,k}$ jest elementem zbioru U^i , a rozpoznawany obiekt to x [1].

Skuteczność algorytmu k -NN mierzona jest na podstawie odsetka poprawnych przyporządkowań obiektów do odpowiadających im klas.

2.1. Ekstrakcja cech, wektory cech

Pierwszym etapem, który należy wykonać w procesie rozpoznawania tekstów jest wyodrębnienie takich cech, aby jak najlepiej określały ich charakterystykę. Wszystkie artykuły są napisane w tym samym języku oraz w tej samej formie stylistycznej, dlatego w trakcie analizy skupiliśmy się na cechach liczbowych oraz tekstowych. Mając to na uwadze, dokonaliśmy ekstrakcji poniższych cech:

1. Zapis cyfr - za pomocą analizy ciągu cyfr otrzymamy informacje o np. numerach telefonicznych, które to są charakterystyczne dla omawianego kraju. Z pomocą symboli matematycznych ceche tą możemy zapisać następująco:

$$c_1 = \frac{|s : s \in N \wedge s \in P_k|}{w} \quad (2)$$

gdzie N - zbiór ciągów cyfr znalezionych w dokumencie, P - zbiór charakterystycznych ciągów cyfr dla danego kraju k , w - waga przez jaką należy podzielić otrzymaną cechę.

Wzór ten zastosujemy dla każdego z rozpatrywanych krajów i dzięki porównaniu otrzymanych wyników uzyskamy informacje do której grupy, na podstawie tej cechy, sklasyfikować dany dokument.

Przykład 2.1. *Fragment artykułu pt. "Offers USA direct service in Denmark" [3]*

"[...]/The service allows callers in Denmark to reach an ATT operator in the United States by dialing a single telephone number, 0430-0010, ATT said.[...]"

Z powyższego fragmentu możemy wyodrębnić ciąg cyfr 0430-0010 i na jego podstawie sklasyfikować, do jakiej etykiety kraju możemy zaklasyfikować dany artykuł. Numery telefonów z różnych krajów mogą być rozpoznane na podstawie np. numeru kierunkowego, ich długości czy też formatu zapisu.

2. Waluty - wyciągnięcie z tekstów nazw najczęściej używanych walut. Każdy z krajów posługuje się inną walutą ¹, dlatego jest to cecha, która jasno

¹ Omawiane artykuły pochodzą z lat 80, kiedy we Francji i w Niemczech obowiązywała inna waluta (odpowiednio frank francuski i marka niemiecka). Kraje te przyjęły wspólną walutę, tj. euro dopiero w 2002 roku

charakteryzuje nam wybrane kraje. Wzory do tej cechy będą prezentowały się następująco:

$$c'_2 = d_t(M) \quad (3)$$

gdzie d_t jest funkcją wyznaczającą t najczęściej występujących słów w danym zbiorze, M to zbiór znalezionych w artykule słów oznaczających waluty.

$$c_2 = g_k(c'_2) \quad (4)$$

gdzie g_k jest funkcją przyporządkowującą wyznaczone słowa do poszczególnego kraju k .

W wyniku porównania otrzymanych dla każdego kraju wartości będziemy mogli stwierdzić do którego kraju, na podstawie tej cechy, można przyporządkować podany tekst.

Przykład 2.2. *Fragment artykułu pt. "Maxtor agrees to acquire U.S. design" [3]*

"[...]They said the arrangement, which is subject to a number of conditions including U.S. Design shareholder approval, calls for Maxtor to issue 12 mln dlrs worth of its own common stock in exchange for all of U.S. Design.[...]"

W powyższym fragmencie została wymieniona waluta o nazwie dolar ("dlrs"). Mimo, że najbardziej popularnym dolarem jest dolar amerykański, natomiast na świecie jest jeszcze wiele innych walut, których pierwszym członem jest słowo "dolar", np. dolar kanadyjski, dolar australijski. Ten fakt należy również wziąć pod uwagę w momencie wyznaczania zbiorów rozmytych. Z podanego fragmentu wynika także, że aby w pełni skorzystać z tej cechy, należy uwzględnić nie tylko pełne nazwy walut, ale również ich skróty, które również się pojawiają w artykułach.

3. Częstość występowania dat - zliczenie, jak często w podanych tekstach występują elementy określające czas. Wydaje się, że ich częstość będzie się różnić w zależności od pochodzenia tekstu. Powyższą cechę można przedstawić następująco:

$$c_3 = \frac{|s : s \in D \wedge s \in A|}{|A|} \quad (5)$$

gdzie D - zbiór słów oznaczających daty, A - zbiór wszystkich słów z artykułu.

Przykład 2.3. *Fragment artykułu pt. "USDA comments on export sales" [3]*

"[...] In comments on its Export Sales Report, the department said sales of 1.0 mln tonnes to the USSR – previously reported under the daily reporting

system – were the first sales for delivery to the USSR under the fourth year of the U.S.-USSR Grains Supply Agreement, which began October 1. [...] Egypt, Japan and Iraq were the major wheat buyers for delivery in the current year, while sales to China decreased by 30,000 tonnes for the current season, but increased by 90,000 tonnes for the 1987/88 season, which begins June 1. [...]”.

W przytoczonym fragmencie zapis daty został wykorzystany 3 razy (“October 1”, “1987/88”, “June 1”). Wobec tego, uważamy, że opisywana cecha będzie korzystnie wpływać na proces klasyfikacji tekstów.

4. Format zapisu dat - w zależności od kraju format zapisu dat różni się. Cechę tą zapisać można za pomocą wzorów:

$$c'_4 = f(B) \quad (6)$$

gdzie f - funkcja wyznaczająca zapis datowy z podanego zbioru, B - zbiór wszystkich wyrażeń znajdujących się w artykule (wyrażenie traktujemy jako połączenie minimum dwóch słów).

$$c_4 = t_k(c'_4) \quad (7)$$

gdzie t_k jest funkcją przyporządkowującą wyznaczone wyrażenia do poszczególnego kraju k .

Jako, że w kilku krajach stosowany jest ten sam zapis datowy, funkcja ta może (a wręcz jest to bardzo prawdopodobne) zwrócić taką samą wartość dla kilku krajów. W wyniku porównania otrzymanych dla każdego kraju wartości będziemy mogli stwierdzić do którego kraju (bądź kilku krajów z równym prawdopodobieństwem), na podstawie tej cechy, można przyporządkować podany tekst.

Przykład 2.4. *Fragment artykułu pt. "Software services extends warrants" [3]*

"[...]Software Services of America Inc said its board has extended the expiration date of its warrants until August 31 from April 30.[...]"

Daty występujące w tym fragmencie ("August 31" i "April 30") są zapisane w formacie: miesiąc dzień. Uważamy, że w zależności od tego, z jakiego kraju pochodzi artykuł format zapisu dat może się różnić.

5. Ogólna liczba słów - zliczenie wszystkich słów występujących w tekście. Uważamy, że w zależności od tego, jakiego kraju tekst dotyczy, ich długość może być różna. Liczbę wyrazów znajdujących się w tekście można przedstawić następująco:

$$c_5 = |A| \quad (8)$$

gdzie A - zbiór wszystkich słów z artykułu.

6. Częstość słów rozpoczynających się wielką literą - słowa takie będą oznaczały najczęściej nazwy własne np. imiona, nazwiska, nazwy budynków lub będą to rozwinięcia skrótów. Pisząc o jednym kraju może być używane więcej takich słów, a o innych mniej. Z tej grupy wykluczamy jednak wyrazy składające się wyłącznie z wielkich liter (o których mowa będzie w punkcie następnym) oraz słowa pisane z wielkiej litery z uwagi na początek zdania. Aby odróżnić wielkie litery od małych, trzeba na początku dokonać odwzorowania liter w słowie na kody ASCII i następnie sprawdzić, czy odpowiedni kod ASCII znajduje się w przedziale od 65 do 90. W postaci wzoru wygląda to następująco:

$$f(l) = \begin{cases} 1 & \text{jeśli } l \in \langle 65, 90 \rangle \\ 0 & \text{jeśli } l \notin \langle 65, 90 \rangle \end{cases} \quad (9)$$

gdzie l oznacza pojedynczy znak zapisany za pomocą kodu ASCII, a funkcja $f(l)$ zwraca 1 dla liter zapisanych wielką literą, a 0 dla pozostałych znaków. Natomiast w celu obliczenia częstości słów rozpoczynających się wielką literą należy skorzystać z poniższego wzoru:

$$c_6 = \frac{|s : s \in Z \wedge s \notin W \wedge s \notin M|}{|A|} \quad (10)$$

gdzie Z - zbiór słów, rozpoczynających się w artykule wielką literą, A - zbiór wszystkich słów z artykułu, W - zbiór słów, pisanych w artykule wielkimi literami, M - zbiór słów, które rozpoczynają w artykule zdania.

Przykład 2.5. *Fragment artykułu pt. "U.S. Auto Union will fight to stop job/wage cuts" [3]*

"[...]The United Auto Workers union (UAW) vowed to fight wage and job cuts in a round of labour talks starting in July that cover nearly 500,000 workers at General Motors Corp and Ford Motor Co[...]".

W tym krótkim fragmencie występuje aż 9 słów rozpoczynających się wielką literą, jednocześnie nie będących pierwszym słowem w zdaniu oraz nie będących słowem składających się tylko z wielkich liter. Słowa te są w tym fragmencie związane z nazwami własnymi oraz nazwą miesiąca. Uważamy, że przede wszystkim stosowanie nazw własnych może być związane z tym, z jakiego kraju pochodzi podany dokument.

7. Częstość słów pisanych wielkimi literami - najczęściej będą to skróty. Uważamy, że w zależności od opisywanego kraju, ilość wykorzystywanych skrótów może się różnić. Do policzenia wystąpień słów zapisanych wielkimi literami należy wykorzystać poniższy wzór:

$$c_7 = \frac{|s : s \in W|}{|A|} \quad (11)$$

gdzie W - zbiór słów, pisanych w artykule wielkimi literami, A - zbiór wszystkich słów z artykułu.

Przykład 2.6. *Fragment artykułu pt. "France approves large defence spending increase" [3]*

"[...]The budget represents a six pct annual increase, starting next year, well above the 3.5 pct NATO recommends for members of its military command. France is a member of NATO but does not belong to its integrated military command.[...]"

W powyższym fragmencie skrót NATO(Organizacja Traktatu Północnoatlantyckiego) występuje 2 razy. Według nas, częstość występowania skrótów, w danym artykule może mieć związek z tym, jakiego kraju dotyczy tekst.

8. Układ SI/imperialny - zdecydowanie częściej w artykułach z krajów anglojęzycznych będzie stosowany układ imperialny, natomiast w pozostałych - układ SI. Wyliczenie liczby wystąpień jednostek w układzie SI można wyrazić następująco:

$$c'_8 = \frac{|s : s \in S \wedge s \in A|}{|A|} \quad (12)$$

gdzie S - zbiór słów oznaczających jednostki układu SI, A - zbiór wszystkich słów z artykułu.

Z kolei wzór do wyliczenia liczby wystąpień jednostek w układzie imperialnym przedstawia się w poniższy sposób:

$$c''_8 = \frac{|s : s \in I \wedge s \in A|}{|A|} \quad (13)$$

gdzie I - zbiór słów oznaczających jednostki układu imperialnego, A - zbiór wszystkich słów z artykułu. Jako opisywaną cechę zapisujemy różnicę wystąpień jednostek w układzie SI oraz imperialnym, czyli:

$$c_8 = c'_8 - c''_8 \quad (14)$$

Przykład 2.7. *Fragment artykułu pt. "Sun in North Dakota oil find" [3]*
"[...]flowed 660 barrels of oil and 581,000 cubic feet of natural gas per day through a 13/64 inch choke from depths of 13,188 to 13,204 feet.[...]"

W powyższym tekście można zauważyć występowanie jednostek z układu imperialnego, tj. cale(inch) i stopy(feet). Wobec tego, można przypuszczać, że tekst ten pochodzi z jednego z krajów anglojęzycznych.

9. Częstość występowania cytatów - kolejna cecha, która wydaje się różnić w zależności od kraju, o którym mowa w artykule. Liczba cytatów zostanie uzyskana w wyniku obliczenia liczby występowania słów, gdzie przedostatni znak to ',', lub '.', a ostatni '"'. Wyznaczenie tej cechy można zaprezentować w postaci wzoru:

$$c_9 = \frac{|s : s \in Y|}{|A|} \quad (15)$$

gdzie Y - zbiór cytatów występujących w artykule, A - zbiór wszystkich słów z artykułu.

Przykład 2.8. *Fragment artykułu pt. "Hughes changes stance on merger after suit" [3]*

"[...]I think the merger is not going through," said Phil Pace, analyst at Kidder, Peabody and Co. He said the merger "lost a lot of its appeal" when the U.S. Department of Justice required that Baker sell off its Reed Tool Co operation.[...]"

W podanym fragmencie cytat wystąpił 2 razy. Uważamy, że artykuły dotyczące różnych krajów będą też zawierały różną liczbę cytatów.

10. Słowa kluczowe - sporządzone zostaną listy elementów identyfikujących każdy z krajów. Określenia te będą związane z elementami charakterystycznymi dla danego kraju. Możemy do nich zaliczyć nazwy geograficzne, znane osoby, nazwy firm itp.. Do wyznaczenia słów kluczowych należy skorzystać ze wzoru:

$$c_{10} = \frac{|s : s \in K \wedge s \in A|}{|A|} \quad (16)$$

gdzie K - zbiór słów kluczowych, A - zbiór wszystkich słów z artykułu.

Przykład 2.9. *Fragment artykułu pt. "Currency futures to key off G-5, G-7 meetings" [3]*

"[...]News of an agreement among G-5 and G-7 finance ministers meeting in Washington this week will be key to the direction of currency futures at the International Monetary Market, but any such agreement will need to go beyond the Paris accord to stem the recent rise in futures, financial analysts said.[...]"

Powyższy tekst zawiera 2 słowa kluczowe - Washington i Paris. Washington związane jest z USA, natomiast Paris z Francją. Chcąc przyporządkować ten fragment biorąc pod uwagę tylko i wyłącznie cechę związaną ze słowami kluczowymi zostałby dopasowany z równym prawdopodobieństwem do Francji lub USA.

11. Najczęściej występujące słowa - wyodrębnienie z artykułów najczęściej występujących słów, z pominięciem słów znajdujących się na tzw. stopliście, tj. liście najczęściej używanych słów w języku angielskim [2]. Zabieg ten ma na celu podniesienie jakości klasyfikacji poprzez wyszukanie słów, które charakteryzują treść artykułu. Pominięcie tej operacji skutkowałoby niejednoznacznym zaklasyfikowaniem tekstów, co w konsekwencji obniżyłoby skuteczność algorytmu. Wyznaczenie opisywanej cechy można przedstawić w postaci operacji na zbiorach:

$$c_{11} = d_t(A - S) \quad (17)$$

gdzie d_t jest funkcją wyznaczającą t najczęściej występujących słów w danym zbiorze, A to zbiór słów w artykule, a S jest zbiorem słów znajdujących się na stopliście.

Przykład 2.10. *Fragment artykułu pt. "Houston oil trust" [3]*

"[...] The most significant factor for the lack of a distribution this month is the establishment of additional special cost escrow accounts, the company said, adding, that there may be no cash distribution in other months or during the remainder of the year [...]"

Dla powyższego przykładu założmy, że stoplista obejmuje 100 najczęściej używanych słów w języku angielskim. Stosując wzór (2) okazuje się, że najczęściej występującym charakterystycznym słowem jest distribution, które pojawiło się w tekście 3 razy.

Ostatecznie, wektor wyekstrahowanych cech będzie się prezentował następująco:

$$v = [c_1, c_2, c_3, c_4, c_5, c_6, c_7, c_8, c_9, c_{10}, c_{11}] \quad (18)$$

2.2. Miary jakości klasyfikacji

Podczas procesu klasyfikacji niezbędne jest określenie jak skuteczna i jakościowa jest prowadzona klasyfikacja. W tym celu posłużyliśmy się tablicą(macierzą) pomyłek oraz miarami jakości klasyfikacji.[5] Macierz pomyłek zawiera ilość próbek przypisanej do poszczególnej grupy (prawdziwie pozytywna, fałszywie pozytywna, fałszywie negatywna, prawdziwie negatywna). Grupy te powstają poprzez zestawienie ze sobą klasy rzeczywistej oraz klasy predykowanej. Tablica pomyłek prezentuje się następująco:

		Klasa rzeczywista	
		pozytywna	negatywna
Klasa predykowana	pozytywna	prawdziwie pozytywna (TP)	fałszywie pozytywna (FP)
	negatywna	fałszywie negatywna (FN)	prawdziwie negatywna (TN)

Tabela 1. Tablica pomyłek

Zostały wykorzystane następujące miary jakości, które zostaną przedstawione wzorami, w których oznaczenia odnosić się będą do Tabeli 1:

— Accuracy (dokładność) - miara, która oznacza dokładność całej klasyfikacji:

$$ACC = \frac{TP + TN}{L} \quad (19)$$

gdzie L - liczba wszystkich sklasyfikowanych próbek

- Precision (precyzja) - miara oznaczająca jak często określoną klasę udało się zakwalifikować poprawnie:

$$PPV = \frac{TP}{TP + FP} \quad (20)$$

- Recall (czułość) - określa jak dużo wystąpień obiektów danej klasy zakwalifikowaliśmy do tejże klasy:

$$TPR = \frac{TP}{TP + FN} \quad (21)$$

- F1 - miara stanowiąca średnią harmoniczną z miar Precision i Recall [6]:

$$F_1 = 2 \cdot \frac{PPV \cdot TPR}{PPV + TPR} \quad (22)$$

Dla przykładu obliczmy miary jakości dla poniższej tabeli:

		Klasa rzeczywista	
		<i>Japonia</i>	$\sim \textit{Japonia}$
Klasa predykowana	<i>Japonia</i>	56	12
	$\sim \textit{Japonia}$	17	36

Tabela 2. Tablica pomyłek z przykładowymi danymi

$$ACC = \frac{56 + 36}{121} = 0,76 \quad (23)$$

$$PPV = \frac{56}{56 + 12} = 0,82 \quad (24)$$

$$TPR = \frac{56}{56 + 17} = 0,77 \quad (25)$$

$$F_1 = 2 \cdot \frac{0,82 \cdot 0,77}{0,82 + 0,77} = 0,79 \quad (26)$$

3. Klasyfikacja z użyciem metryk i miar podobieństwa tekstów

Jak już zostało wspomniane w rozdziale 2., algorytm k-NN należy do grupy algorytmów minimalnoodległościowych. Aby zaimplementować jego działanie niezbędna jest zatem metryka, która pozwoli w transparentny sposób wyznaczyć odległości pomiędzy wektorami cech. Z tego względu, w ramach badań zostaną wykorzystane trzy poniższe rodzaje metryk:

- Euklidesowa - aby obliczyć odległość pomiędzy dwoma wektorami cech należy obliczyć pierwiastek z sumy kwadratów różnic wszystkich kolejnych cech obu wektorów. Wzór opisujący metrykę Euklidesową wygląda następująco [1]:

$$\rho_1(c^\mu, c^\eta) = \sqrt{\sum_{\nu=1}^n (c_\nu^\mu - c_\nu^\eta)^2} \quad (27)$$

,gdzie c^μ oraz c^η oznaczają wektory cech, natomiast n jest to liczba cech, a ν to numer cechy

Przykład 3.1. *Obliczanie metryki Euklidesowej*

Dajmy dwa wektory cech:

$$c^\mu = [1, 2, 3] \quad (28)$$

$$c^\eta = [-2, -3, -4] \quad (29)$$

Wynik obliczenia metryki euklidesowej przedstawia się następująco:

$$\rho_1(c^\mu, c^\eta) = \sqrt{(1 - (-2))^2 + (2 - (-3))^2 + (3 - (-4))^2} \quad (30)$$

$$\rho_1(c^\mu, c^\eta) = \sqrt{3^2 + 5^2 + 7^2} \quad (31)$$

$$\rho_1(c^\mu, c^\eta) \approx 9.11 \quad (32)$$

- uliczna - w celu obliczenia metryki ulicznej należy obliczyć sumę wartości bezwzględnych z różnic pomiędzy kolejnymi cechami z obu wektorów. Wzór opisujący metrykę uliczną wygląda następująco [1]:

$$\rho_2(c^\mu, c^\eta) = \sum_{\nu=1}^n |c_\nu^\mu - c_\nu^\eta| \quad (33)$$

Przykład 3.2. *Obliczanie metryki ulicznej*

Dajmy dwa wektory cech:

$$c^\mu = [3, 5, 8] \quad (34)$$

$$c^\eta = [-2, 0, 10] \quad (35)$$

Wynik obliczenia metryki ulicznej przedstawia się następująco:

$$\rho_2(c^\mu, c^\eta) = |3 - (-2)| + |5 - 0| + |8 - 10| \quad (36)$$

$$\rho_2(c^\mu, c^\eta) = 12 \quad (37)$$

- Czebyszewa - aby obliczyć metrykę Czebyszewa należy wyznaczyć maksymalną wartość bezwzględną z różnic pomiędzy kolejnymi cechami z obu wektorów. Wzór opisujący tę metrykę wygląda następująco [1]:

$$\rho_3(c^\mu, c^\eta) = \max_{1 \leq \nu \leq n} |c_\nu^\mu - c_\nu^\eta| \quad (38)$$

Przykład 3.3. *Wykorzystanie metryki Czebyszewa*

Dajmy dwa wektory cech:

$$c^\mu = [6, 3, 5, -1] \quad (39)$$

$$c^\eta = [3, 4, 1, 9] \quad (40)$$

Wynik obliczenia metryki ulicznej przedstawia się następująco:

$$\rho_3(c^\mu, c^\eta) = \max|6 - 3|, |3 - 4|, |5 - 1|, |-1 - 9| \quad (41)$$

$$\rho_3(c^\mu, c^\eta) = 10 \quad (42)$$

Nie wszystkie wartości w wektorze cech są od razu zapisane w formie liczbowej, niektóre z nich są w postaci tekstowej. W tym celu należy zaimplementować miarę podobieństwa tekstów, która zamieni elementy wektora cech z postaci tekstowej na postać liczbową. W naszej aplikacji w tym celu wykorzystaliśmy Uogólnioną miarę n-gramów.[7] Zwykła metoda n-gramów określa podobieństwo łańcuchów tekstowych s_1, s_2 w oparciu o ilość wspólnych podciągów n-elementowych, (np. dla $n=3$ badamy podobieństwo słów w oparciu o podciągi 3-literowe). Zastosowana przez nas miara jest dokładniejsza, jednak bardziej kosztowna obliczeniowo - sprawdza ona podciągi różnej długości, od jedno- do N-elementowych, gdzie N jest długością słowa. Wyraża się ona wzorem:

$$\mu_N(s_1, s_2) = \frac{2}{N^2 + N} \sum_{i=1}^{N(s_1)} \sum_{j=1}^{N(s_1)-i+1} h(i, j) \quad (43)$$

gdzie

$h(i, j) = 1$ jeśli i -elementowy podciąg w słowie s_1 zaczynający się od j -tej pozycji w słowie s_1 pojawia się przynajmniej raz w słowie s_2 (inaczej $h(i, j) = 0$);

$N(s_1), N(s_2)$ - ilość liter w słowach s_1 i s_2 ;

$N = \max\{N(s_1), N(s_2)\}$

$\frac{N^2+N}{2}$ - ilość możliwych podciągów od 1-elementowych do N-elementowych w słowie o długości N.

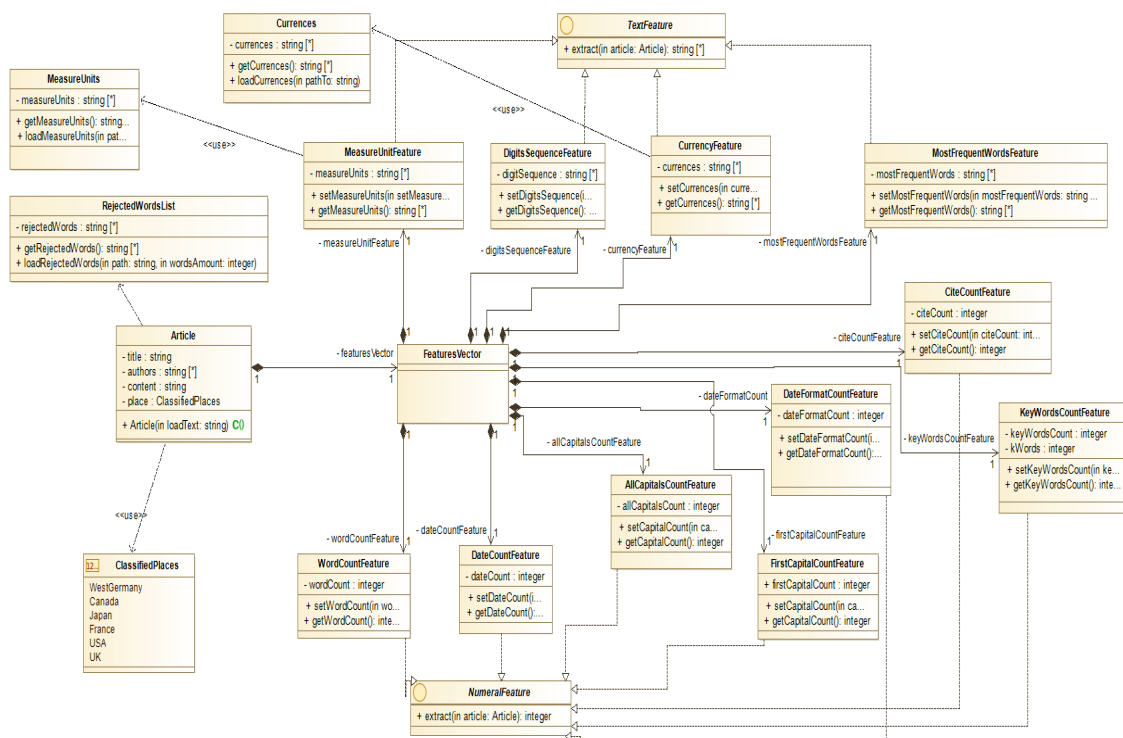
4. Budowa aplikacji

4.1. Diagramy UML

Nasza aplikacja będzie się składać z 4 modułów: moduł ekstrakcji, moduł klasyfikatora, moduł DAO (zarządzanie wczytywaniem danych z plików) oraz moduł interfejsu graficznego.

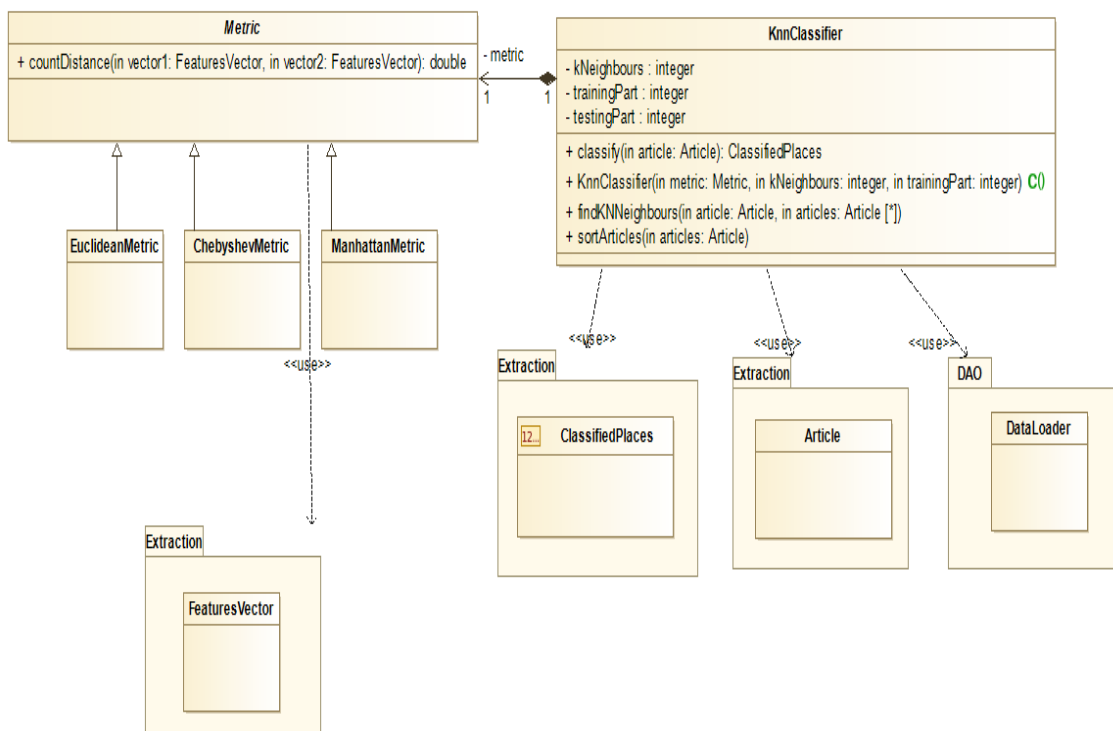
Moduł ekstrakcji będzie odpowiedzialny za odwzorowanie tekstu na wektor cech. Wektor cech zaimplementowany zostanie z wykorzystaniem klasy FeaturesVector. W klasie FeaturesVector znajduje się 11 pól, każde oznaczające jedną z cech, które zostały przez nas wybrane i przedstawione w sekcji 2. Dla każdej cechy stworzona została odpowiadająca klasa. Każda z klas, która reprezentuje cechę, implementuje interfejs: dla cech liczbowych jest to interfejs NumericFeature, natomiast dla cech tekstowych jest to interfejs TextFeature. Oba interfejsy mają metodę extract(Article article), różnica polega na zwracanej wartości. W pierwszym przypadku jest to liczba typu integer (oznaczająca obliczoną liczbę np. słów w tekście), zaś w drugim

przypadku jest to lista ciągów znaków (oznaczająca wyznaczoną, znalezioną listę wyrazów, które spełniają warunki danej klasy).



Rysunek 1. Diagram UML dla modułu ekstrakcji

Moduł klasyfikatora będzie odpowiedzialny za klasyfikację artykułów do odpowiednich etykiet places przy pomocy algorytmu kNN. Z tego względu powstanie klasa KnnClassifier, której zadaniem będzie sklasyfikowanie artykułu z wykorzystaniem jednej z trzech metryk, tj. metryki Czebysze-wa, metryki ulicznej (Manhattan) lub metryki euklidesowej. W tym celu powstały cztery klasy: klasa Metric jest to klasa abstrakcyjna, natomiast klasy EuclideanMetric, ChebyshevMetric oraz ManhattanMetric są klasami dziedziczącymi. Poza metryką, niezbędne do klasyfikacji są parametry: liczba najbliższych sąsiadów (kNeighbours) oraz stosunek liczby artykułów w części treningowej do części testowej. Do wykorzystania klasy KnnClassifier niezbędny jest moduł ekstrakcji, ponieważ klasa KnnClassifier wykorzystuje klasę Artykuł oraz kategorie ClassifiedPlaces znajdujące się w typie enumerate.



Rysunek 2. Diagram UML dla modułu klasyfikatora

4.2. Prezentacja wyników, interfejs użytkownika

Aplikacja została wykonana w technologii Java w wersji 11[8] (najnowsza wersja LTS) przy wykorzystaniu Apache Maven w wersji 3.6.3[9]. Do stworzenia interfejsu graficznego posłużyliśmy biblioteką JavaFX w wersji 13[10]. W celu uruchomienia aplikacji należy po zainstalowaniu Maven na własnym komputerze, z poziomu wiersza poleceń znajdując się w folderze głównym projektu wykonać polecenie: `mvn install`, a następnie z wiersza poleceń z poziomu modułu GUI wykonać polecenie: `mvn clean javafx:run`. Aplikację można także uruchomić z poziomu IDE. Po uruchomieniu aplikacji ukaże nam się interfejs użytkownika, w którym możemy wybrać jak ma zostać podzielony zbiór (w jakich proporcjach na część treningową i testową), wczytać pliki, w których znajdują się teksty do analizy, podać liczbę k najbliższych sąsiadów dla klasyfikatora k -NN, wybrać metrykę oraz zbiór cech wykorzystywanych w procesie klasyfikacji oraz wykonać klasyfikację. W efekcie ukażą nam się następujące informacje: liczba wczytanych plików, liczba artykułów podlegających klasyfikacji oraz rezultaty 4 miar podobieństwa - Accuracy, Precision, Recall i F1.

Klasyfikator dokumentów tekstowych

Podział wczytanego zbioru na dwie części:
50 - treningowa / 50 - testowa
0 20 40 60 80 100
Wczytaj pliki

Liczba wczytanych plików: 0
Artykułów do klasyfikacji: 0

Podaj liczbę k najbliższych sąsiadów:
[input field]

Wybierz metrykę i/lub miarę podobieństwa:
Metryka: [dropdown]
Miara podobieństwa: [dropdown]

Wybierz zbiór cech:

- ☒ Ogólna liczba słów
- ☒ Częstość występowania dat
- ☒ Format zapisu dat
- ☒ Waluty
- ☒ Zapis cyfr
- ☒ Częstość słów rozpoczynających się wielką literą
- ☒ Częstość słów pisanych wielkimi literami
- ☒ Jednostki w układzie SI lub imperialnym
- ☒ Częstość występowania cytatów
- ☒ Słowa kluczowe
- ☒ Najczęściej występujące słowa

Zaznacz wszystkie Odznacz wszystkie

Wykonaj klasyfikację

Miara podobieństwa	Rezultat
Accuracy (dokładność)	0.0
Precision (precyzja)	0.0
Recall (czułość)	0.0
F1	0.0

Rysunek 3. Interfejs użytkownika dla aplikacji.

5. Wyniki klasyfikacji dla różnych parametrów wejściowych

Wyniki kolejnych eksperymentów wg punktów 2.-8. opisu projektu 1. Wykresy i tabele obowiązkowe, dokładnie opisane w „captions” (tytułach), konieczny opis osi i jednostek wykresów oraz kolumn i wierszy tabel.

****Ewentualne wyniki realizacji punktu 9. opisu Projektu 1., czyli „na ocenę 5.0” i ich porównanie do wyników z części obowiązkowej**.**

Sekcja uzupełniona jako efekt zadania Tydzień 05 wg Harmonogramu Zajęć na WIKAMP KSR.

6. Dyskusja, wnioski

Dokładne interpretacje uzyskanych wyników w zależności od parametrów klasyfikacji opisanych w punktach 3.-8 opisu Projektu 1. Szczególnie istotne są wnioski o charakterze uniwersalnym, istotne dla podobnych zadań. Omówić i wyjaśnić napotkane problemy (jeśli były). Każdy wniosek/problem powinien mieć poparcie w przeprowadzonych eksperymentach (odwołania do konkretnych wyników: wykresów, tabel).

Dla końcowej oceny jest to najważniejsza sekcja sprawozdania, gdyż prezentuje poziom zrozumienia rozwiązywanego problemu.

** Możliwości kontynuacji prac w obszarze systemów rozpoznawania, zwłaszcza w kontekście pracy inżynierskiej, magisterskiej, naukowej, itp. **

Sekcja uzupełniona jako efekt zadania Tydzień 06 wg Harmonogramu Zajęć na WIKAMP KSR.

7. Braki w realizacji projektu 1.

Wymienić wg opisu Projektu 1. wszystkie niezrealizowane obowiązkowe elementy projektu, ewentualnie podać merytoryczne (ale nie czasowe) przyczyny tych braków.

Literatura

- [1] R. Tadeusiewicz: Rozpoznawanie obrazów, PWN, Warszawa, 1991.
- [2] Corpus of Contemporary American English: Most frequent english words [prze-
glądany 20.03.2021], Dostępny w: <https://www.english-corpora.org/>
- [3] Repozytorium Uniwersytetu Kalifornijskiego w Irvine do nauki uczenia ma-
szynowego: Artykuły agencji Reuters[przeglądany 20.03.2021], Dostępny w:
<http://archive.ics.uci.edu/ml/machine-learning-databases/reuters21578-mld/>
- [4] A. Niewiadomski, Methods for the Linguistic Summarization of Data: Appli-
cations of Fuzzy Sets and Their Extensions, Akademicka Oficyna Wydawnicza
EXIT, Warszawa, 2008.
- [5] Tablica pomyłek [przeglądany 28.03.2021], Dostępny w:
https://pl.wikipedia.org/wiki/Tablica_pomyłek
- [6] F-score [przeglądany 28.03.2021] Dostępny w:
<https://en.wikipedia.org/wiki/F-score>
- [7] A. Niewiadomski, Materiały, przykłady i ćwiczenia do przedmiotu Kompute-
rowe Systemy Rozpoznawania, 2020.
- [8] Dokumentacja Java 11 [przeglądany 11.04.2021] Dostępny w :
<https://docs.oracle.com/en/java/javase/11/>
- [9] Dokumentacja Maven 3.6.3 [przeglądany 11.04.2021] Dostępny w:
<https://maven.apache.org/docs/3.6.3/release-notes.html>
- [10] Dokumentacja JavaFx 13 [przeglądany 11.04.2021] Dostępny w:
<https://openjfx.io/javadoc/13/>

Literatura zawiera wyłącznie źródła recenzowane i/lub o potwierdzonej wiarygodności, możliwe do weryfikacji i cytowane w sprawozdaniu.